

République Algérienne Démocratique et Populaire

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Conception et Développement d'un CRM Intelligent

**Intégrant un Module de Prédiction des
Ventes**

**Basé sur le Machine Learning
pour le E-Commerce**

Projet de Stage

Entreprise d'accueil : BAT PROJET ENGINEERING

Représentée par Mr. ATALLAH Mohammed

Réalisé par :

Rezaiguia Soltane Tadj Eddine
(DS)

Bellatreche Mohamed Amine
(DS)

Khelifi Ayyoub (CS)

Brahim Soheib (AI)

Encadré par :

Dr. Khellat Souad

Table des matières

Introduction Générale	1
1 Contexte et Organisme d’Accueil	2
1.1 Présentation de l’organisme d’accueil	2
1.2 Le E-commerce en Algérie	2
2 Problématique	3
3 Solution Proposée et État de l’Art	4
3.1 Solution proposée	4
3.2 État de l’Art	4
4 Conception et Architecture	6
4.1 Architecture Globale du Système	6
4.2 Mécanisme de réentraînement et sécurité	7
5 Réalisation et Évaluation des Modèles ML	8
5.1 1. Modèle de Prédiction du Risque COD	8
5.1.1 Transformation et Modélisation	8
5.2 2. Modèle de Segmentation Client (Clustering)	9
5.3 3. Modèle de Prévision de la Demande	9
Conclusion Générale	10
Bibliographie	11

Table des figures

4.1	Architecture globale du système CRM	7
-----	---	---

Liste des tableaux

Introduction Générale

Le commerce électronique connaît une croissance exponentielle en Algérie, particulièrement dans le modèle *Cash-on-Delivery* (COD), où le paiement s'effectue à la livraison. Ce modèle, bien qu'adapté au contexte local où les solutions de paiement électronique restent limitées, engendre des défis majeurs : un taux d'échec de livraison élevé, des retours coûteux qui érodent les marges, et une gestion inefficace des commandes.

Face à ces problématiques, les CRM traditionnels s'avèrent insuffisants. Ils se limitent à une gestion passive des données. L'intégration de l'intelligence artificielle (Machine Learning) ouvre de nouvelles perspectives pour transformer ces données en leviers décisionnels. Ce projet propose la conception et le développement d'un CRM intelligent pour le e-commerce COD, intégrant :

1. La prédiction du risque de livraison.
2. La segmentation client automatisée.
3. La prévision de la demande adaptée au marché algérien.

Le rapport est structuré autour du contexte, de la problématique, de la solution proposée, de la conception architecturale, et enfin de la réalisation et de l'évaluation des modèles d'intelligence artificielle.

Chapitre 1

Contexte et Organisme d'Accueil

1.1 Présentation de l'organisme d'accueil

Ce projet a été réalisé au sein de l'entreprise **BAT PROJET ENGINEERING**, représentée par Mr. ATALLAH Mohammed. L'entreprise s'intéresse au développement de solutions numériques visant à améliorer les processus opérationnels des e-commerçants en Algérie et à intégrer l'intelligence artificielle dans les outils d'aide à la décision.

1.2 Le E-commerce en Algérie

Le marché numérique algérien se numérise très rapidement, porté par une jeunesse connectée. Cependant, ses spécificités le distinguent des marchés occidentaux :

- **Modèle Cash-on-Delivery (COD) dominant** (>90% des transactions).
- **Logistique vaste** répartie sur 58 wilayas, induisant des délais et coûts de transport variables.

Chapitre 2

Problématique

Le modèle COD, bien qu'incontournable, expose les commerçants à une **problématique économique et logistique sévère** :

1. **Taux d'échec de livraison élevé** : 30 à 50% des commandes COD ne sont jamais livrées (refus, injoignabilité du client).
2. **Explosion des coûts** : Chaque commande échouée entraîne des frais de retour assumés par le vendeur.
3. **Limites opérationnelles** : La confirmation manuelle et le manque d'indicateurs prédictifs empêchent d'anticiper les échecs ou les tendances de consommation (ex : lors d'événements comme le Ramadan).

Le défi consiste donc à doter les e-commerçants d'un outil opérationnel (CRM) et analytique, capable de prédire *a priori* le comportement d'une commande COD et de fournir des recommandations ciblées.

Chapitre 3

Solution Proposée et État de l’Art

3.1 Solution proposée

Notre solution repose sur la conception et le développement d’un **CRM Intelligent multilingue** (Arabe, Français, Anglais). Contrairement à un CRM classique de 1^{re} ou 2^e génération, notre architecture de 3^e génération est centrée sur le **Machine Learning**. Les fonctionnalités clés incluent :

- Un tableau de bord unifié pour la gestion des stocks, commandes et livraisons.
- L’attribution automatique d’un *Score de Risque* pour chaque commande COD grâce aux modèles d’ensemble.
- Une segmentation adaptative de la clientele (RFM hybride).
- La découverte de tendances avec un moteur de prévision *time-series* incluant les jours fériés et le calendrier islamique.
- La génération d’insights périodiques via LLM.

3.2 État de l’Art

Pour répondre aux objectifs du projet, nous avons exploré différentes familles d’algorithmes et approches ML :

- **Gradient Boosting pour la prédiction tabulaire** : XGBoost, LightGBM et CatBoost [3, 4, 5]. Leurs mécanismes de boosting séquentiel et la gestion des données catégorielles les rendent idéaux pour le score de risque COD.
- **Séries Temporelles pour la prévision de la demande** : Les modèles traditionnels (ARIMA) ou profonds sans covariables peinent sur des historiques courts. L’injection d’ingénierie des features (lag, rolling-mean) et de covariables catégorielles (calendrier islamique) fait briller les algorithmes supervisés comme LightGBM [4].

- **Clustering Hybride** : L'utilisation conjointe de **HDBSCAN** [6] (pour repérer des formes complexes avec gestion de bruit sur de larges volumes, >1000) et de **KMeans** (efficace et stable sur de petites grappes de données de marchands naissants).
- **Rééchantillonnage résilient (ADASYN / SMOTE)** [1, 2] : Pour pallier au sévère déséquilibre du dataset Olist, nous avons identifié l'approche **ADASYN** qui se concentre sur les échantillons minoritaires difficiles à déterminer.


Chapitre 4

Conception et Architecture

4.1 Architecture Globale du Système

Le système adopte une architecture **microservices** répartie entre :

1. **Frontend (Next.js)** : Interface utilisateur réactive.
2. **Backend Core (PHP 8.2)**
Architecture Clean (Controller-Service-Repository). Elle expose une API REST stricte et communique avec MySQL 8.0 en configuration Multi-Tenant.
3. **Microservice ML (Python / FastAPI)** : Service indépendant hébergeant les modèles CatBoost/LightGBM/XGBoost, exposant des routes de scoring et gérant les pipelines d'entraînement et LLM (Google Gemini).



Le cycle de vie opérationnel (depuis la réception jusqu'à la livraison) passe de *Pending* à *Delivered/Returned* en interrogeant systématiquement l'API FastAPI afin de générer l'alerte sur le risque. Le schéma relationnel inclut 12 tables dont les entités métiers (stores, produits, wilayas, inventaire, mouvements, orders) séparées thématiquement.

4.2 Mécanisme de réentraînement et sécurité

Pour rester pertinent face à la dynamique spécifique à chaque boutique, le système supporte un pipeline auto-organisé :

- **Optuna Automation** : Recherche bayésienne d'hyperparamètres chaque fois que de nouvelles données validées sont asynchronement poussées depuis MySQL vers le module ML.
- **Sécurité** : Tous les endpoints sont protégés par tokens JWT ségrégués (tenant-scoping). Les requêtes SQL sont ascriptées et sanitisées contre les injections, validées via des middlewares stricts.

Chapitre 5

Réalisation et Évaluation des Modèles ML

Faute de base algérienne ouverte, l'outil s'appuie d'abord sur le benchmark **Olist Brazilian E-Commerce** [7]. Ce jeu de données a servi de point de départ pour valider le pipeline, avant d'être retraité par mapping (états $\rightarrow$ wilayas, devise BRL $\rightarrow$ DZD, suppression des états de transition) afin d'obtenir une classification binaire claire : Livraison vs Échec.

5.1 1. Modèle de Prédiction du Risque COD

Formulé comme une classification binaire, le dataset met en évidence un fort déséquilibre ($>98\%$ livrés).

5.1.1 Transformation et Modélisation

31 variables ont été sélectionnées sans data-leakage, couvrant le temporal, la qualité produit, la zone géographique, et les vecteurs de paiement. ADASYN a été retenu en phase d'entraînement, accompagné d'une optimisation par Optuna. L'ensemble de modèles (*Soft-Voting* CatBoost, XGBoost, LightGBM) offre :

- **AUC-ROC** : 0.9961
- **Rappel d'échecs** : de 25,4% avant Optuna, à **98,0%** après optimisation (FN = 0 sur la détection des anomalies graves!).
- La *Statistique J de Youden* fixe un seuil discriminant de 0.9805 dictant un score d'incertitude bénéfique pour le marché COD.

Les résultats orientent le réseau vers l'automatisation de l'écran, attribuant les actions visuelles critiques (Alerte, Revue, Approbation) selon des seuils (0-30 = Critique, 30-70

= Modéré, etc.).

5.2 2. Modèle de Segmentation Client (Clustering)

L'analyse *Recency, Frequency, Monetary (RFM)* est traitée automatiquement selon une règle algorithmique de volume :

- Si $N \geq 1000$ (**Boutiques évoluées**) : Exécution de **HDBSCAN** qui capture les distributions singulières avec débruitage automatique (a généré 5 méta-segments sur Olist).
- Si $N < 1000$ (**Nouveaux accédants**) : Exécution de **K-Means** (k optimisé par la métrique de Silhouette).

5.3 3. Modèle de Prédiction de la Demande

Il est conçu pour capter les schémas annuels, particulièrement religieux. Bien que des approches "Deep" exogènes (ex : Chronos-T5 [8]) eussent été testées, un réseau profond nécessite énormément de données. Notre benchmark confirme que **LightGBM sur data formatée Time-Series** gagne (-12.2% sur la métrique MAE) grâce à l'injection d'ingénierie avancée :

- Covariables **hijri-converter** : Ramadan, Aïd, Mawlid, dates clés (1er nov, janvier...).
- Indicateurs linéaires statistiques : Lags, Moyennes et Déviations glissantes.
- Résultat : MAE = 318,741 DZD, supplantant ARIMA, Moving Average ou Chronos.

L'intégration native de l'API **Google Gemini** boucle la boucle en traduisant les signaux et graphes résultants en **rapports auditifs structurés multilingues** (Arabe, English, French).

Conclusion Générale

Ce stage d'ingénierie a abouti à un ensemble cohérent couvrant le développement logiciel, l'intégration métier et les traitements d'intelligence artificielle. En combinant les couches applicatives standard (NextJS, PHP/MySQL multi-tenant robustes et sécurisés) avec un microservice Python dédié au Machine Learning, l'entreprise BAT PROJET ENGINEERING dispose d'une base solide et évolutive.

L'objectif pédagogique principal — marier algorithmes avancés et intégration sécurisée d'entreprise pour le commerce — est atteint. Les résultats comparatifs de classification de risques, renforcés par Optuna, ADASYN et les 31 variables sélectionnées sans fuite d'information, apportent une fiabilité immédiate au déploiement. Les perspectives prévoient l'activation asynchrone des modèles sur pipelines Kubernetes à pétition étendue, ainsi que la généralisation du RAG pour le query SQL par agent LLM.

Bibliographie

- [1] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE : Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [2] H. He, Y. Bai, E. A. Garcia, and S. Li, “ADASYN : Adaptive Synthetic Sampling Approach for Imbalanced Learning,” in *Proceedings of the IEEE International Joint Conference on Neural Networks*, pp. 1322–1328, 2008.
- [3] T. Chen and C. Guestrin, “XGBoost : A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, 2016.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM : A Highly Efficient Gradient Boosting Decision Tree,” in *Advances in Neural Information Processing Systems 30*, pp. 3146–3154, 2017.
- [5] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, “Cat-Boost : Unbiased Boosting with Categorical Features,” in *Advances in Neural Information Processing Systems 31*, pp. 6638–6648, 2018.
- [6] L. McInnes, J. Healy, and S. Astels, “hdbscan : Hierarchical density based clustering,” *Journal of Open Source Software*, vol. 2, no. 11, p. 205, 2017.
- [7] Olist, “Brazilian E-Commerce Public Dataset by Olist,” Kaggle, 2018. [Online]. Available : [Kaggle dataset page](#)
- [8] A. F. Ansari, et al., “Chronos : Learning the Language of Time Series,” *arXiv preprint arXiv :2403.07815*, 2024.