

République Algérienne Démocratique et Populaire

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Conception et Développement d'un CRM Intelligent

**Intégrant un Module de Prédiction des
Ventes**

**Basé sur le Machine Learning
pour le E-Commerce**

Projet de Stage

Entreprise d'accueil : BAT PROJET ENGINEERING

Représentée par Mr. ATALLAH Mohammed

Réalisé par :

Rezaiguia Soltane Tadj Eddine
(DS)

Bellatreche Mohamed Amine
(DS)

Khelifi Ayyoub (CS)

Brahim Soheib (AI)

Encadré par :

Dr. Khellat Souad

Table des matières

Introduction Générale	1
1 Présentation de l'Organisme d'Accueil	2
1.1 Profil de BAT PROJET ENGINEERING	2
1.2 Cadre du stage et objectifs attendus	2
1.3 Organisation de l'équipe (4ème année)	3
1.4 Méthode de travail	4
2 Problématique : Contexte, Objectifs et Contraintes	5
2.1 Le e-commerce en Algérie	5
2.2 Problématique du COD	5
2.3 Objectifs du projet	6
2.4 Contraintes du projet	6
2.5 Critères de réussite retenus	7
3 État de l'Art	8
3.1 CRM intelligent et aide à la décision	8
3.2 Techniques ML retenues	8
3.2.1 Classification du risque de livraison	8
3.2.2 Segmentation client	8
3.2.3 Prévission de la demande	9
3.3 Métriques d'évaluation	9
4 Conception et Architecture	10
4.1 Architecture globale du système	10
4.2 Conception de la base de données	11
4.2.1 Schéma relationnel	11
4.2.2 Tables principales	11
4.2.3 Cycle de vie d'une commande COD	12
4.3 Architecture du module ML	12
4.3.1 Intégration IA dans le système	12
4.3.2 Structure du microservice	13
4.3.3 Endpoints de l'API ML	14

4.3.4	Intégration avec le backend PHP	14
5	Réalisation	15
5.1	Technologies utilisées	16
5.2	Le CRM : Modules fonctionnels	17
5.3	Jeu de données : Olist Brazilian E-Commerce	17
5.3.1	Transformation et mapping	17
5.4	Réentraînement des modèles	17
6	Solution Proposée : IA, Résultats et Validation	18
6.1	Pipeline global et logique d'intégration	18
6.2	Démarche de développement : Olist puis CRM	19
6.3	Résultats des modules IA	19
6.3.1	Prédiction du risque de livraison	19
6.3.2	Segmentation client (RFM)	19
6.3.3	Prévision de la demande	19
6.4	Intégration LLM et restitution utilisateur	20
7	Sécurité Applicative et Protection des Données	21
7.1	Méthodologie d'audit	21
7.2	Architecture de protection retenue	21
7.3	Synthèse des corrections intégrées	22
7.4	Préconisations de déploiement	22
7.5	Revue finale de cohérence	22
	Conclusion Générale	23
	Bibliographie	24

Introduction Générale

Le commerce électronique connaît une croissance exponentielle en Algérie, particulièrement dans le modèle *Cash-on-Delivery* (COD), où le paiement s'effectue à la livraison. Ce modèle, bien qu'adapté au contexte local où les solutions de paiement électronique restent limitées, engendre des défis majeurs : un taux d'échec de livraison de 30 à 50%, des retours coûteux qui érodent les marges, et une gestion inefficace des commandes.

Face à ces problématiques, les systèmes de gestion de la relation client (CRM) traditionnels s'avèrent insuffisants. Ils se limitent à la gestion passive des données sans exploiter le potentiel prédictif qu'elles renferment. L'intégration de l'intelligence artificielle, et plus spécifiquement du Machine Learning, dans ces systèmes ouvre de nouvelles perspectives pour transformer les données historiques en informations décisionnelles actionnables.

Le présent travail s'inscrit dans cette démarche et vise à concevoir et développer un CRM intelligent pour le e-commerce COD, intégrant un module de prédiction basé sur le Machine Learning. Ce module comprend trois axes principaux :

1. **La prédiction du risque de livraison** : un ensemble de modèles (CatBoost, LightGBM, XGBoost) pour évaluer la probabilité de succès de chaque commande.
2. **La segmentation client** : une approche hybride HDBSCAN (grands jeux de données) / KMeans (petits jeux de données) pour identifier automatiquement des groupes de clients aux comportements similaires.
3. **La prévision de la demande** : un modèle LightGBM avec covariables du calendrier islamique pour anticiper les tendances de vente futures.

Le rapport suit une progression continue : présentation de l'organisme d'accueil, cadrage du problème, choix méthodologiques, conception/implémentation, validation IA, puis sécurité et conclusion. Cette structure permet de conserver un fil conducteur commun entre enjeux métier, décisions techniques et résultats mesurés.

Chapitre 1

Présentation de l'Organisme d'Accueil

1.1 Profil de BAT PROJET ENGINEERING

Le stage s'est déroulé au sein de **BAT PROJET ENGINEERING**, structure partenaire du projet et environnement d'expérimentation du CRM. L'organisme intervient sur des activités de gestion opérationnelle et de pilotage métier, avec un besoin concret d'outillage numérique pour fiabiliser les processus.

Dans ce contexte, la problématique COD (Cash-on-Delivery) est apparue comme prioritaire : volume de commandes croissant, suivi manuel dispersé, difficulté à anticiper les risques d'échec de livraison et manque d'outils d'aide à la décision.

1.2 Cadre du stage et objectifs attendus

Le stage avait un double objectif :

1. Concevoir un **socle CRM opérationnel** (gestion des clients, commandes, produits, stock, livraisons et retours).
2. Intégrer un **module d'intelligence artificielle** exploitable en conditions réelles pour soutenir la décision métier.

Les livrables validés avec l'organisme d'accueil étaient :

- une application web utilisable avec gestion multi-tenant,
- une API backend sécurisée et documentée,
- un microservice ML déployable indépendamment,
- une documentation technique et méthodologique traçable.

1.3 Organisation de l'équipe (4ème année)

Le projet a été mené par quatre étudiants de 4ème année, avec une répartition explicite des responsabilités pour garantir une production cohérente :

TABLE 1.1 – Répartition des responsabilités principales

Étudiant	Profil	Périmètre principal
Rezaiguia Soltane Tadj Eddine	Data Science	Préparation des données, <i>feature engineering</i> , analyse des métriques et interprétation des résultats.
Bellatreche Mohamed Amine	Data Science	Expérimentations comparatives, évaluation des modèles, structuration des jeux d'entraînement/test.
Khelifi Ayyoub	Computer Science (Cybersécurité)	Backend PHP, architecture applicative, audit de sécurité et implémentation des correctifs.
Brahim Soheib	Artificial Intelligence	Intégration IA/ML, orchestration FastAPI, endpoints d'insights et flux d'interconnexion avec le CRM.

1.4 Méthode de travail

L'organisation du stage a suivi une logique incrémentale :

- décomposition du projet en lots fonctionnels (CRM, IA, sécurité, intégration),
- validation progressive par versions,
- revues croisées entre membres pour limiter les régressions,
- consolidation finale par compilation documentaire et vérification technique.

Cette méthode a permis de conserver un fil directeur commun entre les parties métier, techniques et sécurité, sans perdre la spécificité de chaque domaine.

Chapitre 2

Problématique : Contexte, Objectifs et Contraintes

2.1 Le e-commerce en Algérie

L'Algérie possède un marché e-commerce en pleine expansion, porté par une population jeune et connectée. Cependant, plusieurs spécificités distinguent ce marché :

- **Le modèle COD dominant** : En l'absence de solutions de paiement électronique largement adoptées, plus de 90% des transactions se font en Cash-on-Delivery.
- **La géographie logistique** : Le territoire est divisé en 58 wilayas, regroupées en 3 zones d'expédition avec des coûts et délais variables.
- **La monnaie locale** : Toutes les transactions s'effectuent en Dinar Algérien (DZD).

2.2 Problématique du COD

Le modèle COD présente des défis spécifiques :

1. **Taux d'échec élevé** : 30 à 50% des commandes COD ne sont jamais livrées avec succès (refus, absence, adresse incorrecte).
2. **Coûts de retour** : Chaque commande échouée engendre des frais de transport aller-retour sans recette.
3. **Gestion manuelle** : Les confirmations téléphoniques et le suivi sont souvent manuels et chronophages.
4. **Décisions non informées** : Les gestionnaires manquent d'outils analytiques pour prioriser les commandes ou anticiper les tendances.

2.3 Objectifs du projet

Les objectifs de ce projet sont :

1. **Concevoir un CRM fonctionnel** : Gestion complète des clients, commandes, produits, stocks, livraisons et retours, avec une architecture multi-tenant.
2. **Concevoir rigoureusement la base de données** : Schéma normalisé, audit trails, intégrité référentielle, support multilingue.
3. **Mettre en place un tableau de bord analytique** : Visualisation des KPIs, tendances, et métriques en temps réel.
4. **Développer et comparer des modèles de ML** : Au moins deux modèles pour la prédiction, avec évaluation rigoureuse.
5. **Interpréter les résultats** : Fournir des recommandations actionnables pour l'aide à la décision.

2.4 Contraintes du projet

Le projet a été mené sous plusieurs contraintes structurantes :

1. **Contraintes de données** : absence de dataset COD algérien complet et exploitable au démarrage.
2. **Contraintes métier** : nécessité d'intégrer les spécificités locales (58 wilayas, DZD, calendrier algérien et islamique).
3. **Contraintes système** : interopérabilité entre un backend PHP, un frontend Next.js et un microservice Python.
4. **Contraintes de sécurité** : protection des données clients, isolation multi-tenant et durcissement des endpoints exposés.
5. **Contraintes temporelles** : réalisation dans la fenêtre du stage, avec des jalons de validation académique.

2.5 Critères de réussite retenus

TABLE 2.1 – Critères de réussite métier et technique

Axe	Critère	Indicateur de validation
CRM opérationnel	Flux commande COD couvert de bout en bout	Modules commandes/livraison/retours utilisables et reliés
Architecture	Découplage front-back-ML stable	APIs REST fonctionnelles et déploiement indépendant
IA	Prédictions exploitables par les agents	Scores de risque, segments clients, prévisions disponibles en interface
Sécurité	Exposition contrôlée des services	Authentification, RBAC, tenant scoping, protections anti-injection
Traçabilité	Possibilité de mise à jour des modèles	Réentraînement via base de données ou CSV avec métriques persistées

Chapitre 3

État de l'Art

3.1 CRM intelligent et aide à la décision

Un CRM intelligent dépasse la simple gestion opérationnelle : il transforme les historiques de commandes en décisions concrètes (priorisation des validations, ciblage commercial et anticipation de la demande). Dans ce projet, l'IA est intégrée comme couche d'aide à la décision, sans remplacer les règles métier du CRM.

3.2 Techniques ML retenues

3.2.1 Classification du risque de livraison

La prédiction de risque est traitée comme une classification binaire (succès *vs* échec de livraison). Les trois algorithmes CatBoost [5], LightGBM [4] et XGBoost [3] ont été retenus car ils restent les plus robustes sur données tabulaires [8]. Le système combine leurs scores via un ensemble pondéré afin de limiter la variance.

Le déséquilibre de classes a été traité par ADASYN [2], plus adapté que SMOTE [1] pour renforcer les zones difficiles de la frontière de décision.

3.2.2 Segmentation client

La segmentation repose sur les variables RFM (Recency, Frequency, Monetary). L'implémentation suit une stratégie hybride : HDBSCAN [7] est tenté en priorité pour les gros volumes, puis KMeans est appliqué lorsque la qualité de cluster n'est pas suffisante (silhouette faible ou bruit excessif). Cette logique rend le module exploitable pour des tailles d'entreprise différentes.

3.2.3 Prévision de la demande

Le benchmark a comparé des approches classiques et modernes (baseline interne, Prophet [6], Chronos [10], LightGBM). LightGBM a été retenu en production grâce à son compromis entre performance, temps de réentraînement et facilité d'intégration de covariables calendaires algériennes (jours fériés nationaux et événements islamiques).

3.3 Métriques d'évaluation

Les modèles de risque sont suivis avec AUC-ROC, précision, rappel et F1-Score. Les modèles de prévision sont évalués via MAE et RMSE. Ce choix de métriques est aligné sur l'objectif métier : réduire les échecs COD tout en maintenant une planification logistique stable.

Chapitre 4

Conception et Architecture

4.1 Architecture globale du système

Le système adopté suit une architecture en microservices, composée de trois composants principaux :




FIGURE 4.1 – Architecture globale du système

Le système repose sur une communication REST/JSON entre les composants. Le backend PHP (Clean Architecture, pattern Controller-Service-Repository) orchestre les échanges avec la base MySQL 8.0 (UTF8MB4 pour le multilingue arabe/français) et délègue les traitements analytiques au microservice ML Python (FastAPI). Ce der-

nier intègre un modèle LightGBM avec covariables du calendrier algérien (islamique + jours fériés nationaux) pour la prévision de la demande, ainsi que l'API Google Gemini (`gemini-2.5-flash`) pour la génération d'insights en langage naturel.

4.2 Conception de la base de données

La base de données MySQL comprend **12 tables** réparties en **6 fichiers de migration**, avec une architecture multi-tenant où chaque table opérationnelle est isolée par `store id`.

4.2.1 Schéma relationnel




FIGURE 4.2 – Schéma relationnel de la base de données

4.2.2 Tables principales

Les tables couvrent quatre noyaux :

- gouvernance multi-tenant (`stores`, `users`, `super_admins`),
- référentiels métier (`wilayas`, `products`, `inventory`),
- cycle transactionnel (`orders`, `order_items`, `deliveries`, `returns`),
- traçabilité (`order_status_history`, `inventory movements`).

4.2.3 Cycle de vie d'une commande COD

La table `orders` utilise un champ `status` de type ENUM avec 9 états possibles reflétant le cycle de vie complet d'une commande COD :




FIGURE 4.3 – Cycle de vie d'une commande COD avec intégration IA

4.3 Architecture du module ML

Le module ML est un microservice Python autonome communiquant avec le backend PHP via API REST.

4.3.1 Intégration IA dans le système

La figure 4.4 présente les trois flux d'analyse IA intégrés dans le CRM, ainsi que le composant LLM pour la génération d'insights.




FIGURE 4.4 – Flux d'intégration IA dans le CRM

4.3.2 Structure du microservice

Le microservice est structuré en trois couches :

- **Routes** : exposition des endpoints de prédiction, segmentation, prévision, insights et réentraînement,
- **Services** : orchestration des appels, validation des entrées et interfaçage LLM,
- **Modèles** : pipeline d'entraînement et artefacts persistés (`trained_models`).

4.3.3 Endpoints de l’API ML

TABLE 4.1 – Endpoints opérationnels du module ML

Méthode	Endpoint	Description
POST	/api/predict/order-risk	Prédiction du risque pour une commande
GET	/api/segment/customers	Segmentation des clients
GET	/api/forecast/demand	Prévision de la demande
GET	/api/insights/summary	Insights générés par LLM
GET	/api/insights/order-explanation	Explication textuelle d’un score de risque
POST	/api/retrain/upload-and-train	Réentraîner via CSV
POST	/api/retrain/from-database	Réentraîner depuis la base de données CRM
GET	/api/retrain/metrics	Métriques d’évaluation

4.3.4 Intégration avec le backend PHP

Le backend PHP encapsule les appels ML dans un service applicatif unique (`AIInsightsService`), ce qui centralise la gestion des erreurs, les délais de réponse et l’authentification entre services. Le réentraînement peut ainsi être déclenché depuis l’interface CRM puis tracé dans les métriques de sortie.

Chapitre 5

Réalisation

5.1 Technologies utilisées

TABLE 5.1 – Stack technologique du projet

Composant	Technologie	Version / Détails
Frontend	Next.js (React)	14+ avec TypeScript
Backend	PHP	8.2+ (Clean Architecture)
Base de données	MySQL	8.0+ (UTF8MB4)
Module ML	Python / FastAPI	3.11+ / FastAPI + Uvicorn
Moteurs ML	CatBoost, LightGBM, XGBoost, HDBSCAN/KMeans	Apprentissage supervisé et segmentation
LLM	Google Gemini API	Restitution textuelle d'insights
Conteneurisation	Docker	Python

5.2 Le CRM : Modules fonctionnels

Le CRM couvre l'ensemble du cycle COD : authentification et rôles, catalogue et stock, commandes/livraisons/retours, analytics et administration. Cette couverture opérationnelle est couplée au scoping multi-tenant (`store_id`) et à la journalisation des états sensibles.

5.3 Jeu de données : Olist Brazilian E-Commerce

En l'absence de données algériennes complètes au démarrage, le projet a utilisé Olist [9] comme socle de benchmark (plus de 100 000 commandes réelles, 2016–2018).

5.3.1 Transformation et mapping

Le pipeline applique un mapping vers le contexte local (wilayas, devise DZD, statuts CRM harmonisés, catégories normalisées). Après nettoyage, les commandes finalisées sont utilisées pour l'entraînement du modèle de risque, afin d'éviter les étiquettes ambiguës.

5.4 Réentraînement des modèles

Le réentraînement est activable par deux voies complémentaires :

- depuis le backend CRM (`/api/v1/ai/retrain`),
- directement via le service ML (`/api/retrain/from-database` ou `/api/retrain/upload-and-t`).

Le pipeline suit les étapes suivantes : extraction/validation des données, optimisation Optuna, entraînement des trois modules (risque, segmentation, prévision), puis persistance des métriques dans `metrics.json`. Cette chaîne garantit la traçabilité et la reproductibilité des versions de modèles.

Chapitre 6

Solution Proposée : IA, Résultats et Validation

Ce chapitre synthétise la logique suivie pendant le stage : benchmark initial sur Olist, puis adaptation aux données CRM afin d'obtenir une solution déployable en contexte opérationnel.

6.1 Pipeline global et logique d'intégration

La figure 6.1 montre la chaîne complète (préparation, entraînement, validation, déploiement), en cohérence avec l'architecture applicative (figure 4.1) et les flux d'intégration IA (figure 4.4).




FIGURE 6.1 – Pipeline Machine Learning : de la donnée brute au déploiement

6.2 Démarche de développement : Olist puis CRM

La phase Olist a servi à figer les choix algorithmiques et le protocole d'évaluation. La phase CRM (base interne ou CSV) a ensuite validé l'opérabilité réelle : extraction des données, réentraînement, publication des métriques et exploitation dans l'interface.

6.3 Résultats des modules IA

6.3.1 Prédiction du risque de livraison

Le module de risque utilise 25 variables métier et un ensemble CatBoost/LightGBM/XGBoost. Le protocole conserve un split stratifié, ADASYN pour le déséquilibre et une optimisation Optuna.

TABLE 6.1 – Performances comparatives (benchmark Olist)

Modèle	AUC-ROC	Accuracy	F1
CatBoost	0.9957	0.9997	0.9999
LightGBM	0.9974	0.9997	0.9999
XGBoost	0.9967	0.9996	0.9998
Ensemble	0.9961	0.9997	0.9999

Sur un réentraînement CRM (6 042 commandes), l'ensemble atteint AUC 0.7401 et F1 0.8455. Le score est converti en trois niveaux d'action (faible, intermédiaire, élevé) pour guider la validation COD.

6.3.2 Segmentation client (RFM)

La segmentation RFM applique une logique hybride HDBSCAN/KMeans. Sur la dernière exécution CRM, KMeans est retenu avec 4 segments : VIP (3,1%), Loyal (11,5%), Regular (54,6%) et At Risk (30,9%). Cette sortie est utilisée pour les campagnes de fidélisation et de réactivation.

6.3.3 Prévision de la demande

Le forecasting retient LightGBM avec covariables calendaires algériennes (week-end local, jours fériés, Ramadan et Aïd). Le benchmark Olist reste favorable à cette approche.

TABLE 6.2 – Benchmark forecasting (phase Olist, horizon 30 jours)

Modèle	MAE (DZD)	RMSE (DZD)	Ecart vs baseline
Moyenne mobile (7j)	363 075	466 570	baseline
Chronos-T5-Small	338 231	395 363	+6,8% (MAE)
Prophet + jours islamiques	376 292	447 736	−3,6% (MAE)
LightGBM + covariables	318 741	416 501	+12,2% (MAE)

Sur CRM, la dernière exécution indique MAE 47 111 DZD et RMSE 59 129 DZD, avec une amélioration MAE de 3,1% par rapport à la baseline interne.

6.4 Intégration LLM et restitution utilisateur

Gemini est utilisé pour la restitution explicative (`/api/insights/summary`, `/api/insights/order-e`, `/api/insights/recommendations`) et non pour le scoring principal. Les résultats sont présentés en arabe, français et anglais.

Chapitre 7

Sécurité Applicative et Protection des Données

Le volet cybersécurité formalise les risques identifiés et les correctifs appliqués dans le code afin de garantir un déploiement plus robuste.

7.1 Méthodologie d’audit

1. Revue statique du backend PHP, du frontend Next.js et du microservice FastAPI.
2. Tests dynamiques via Burp Suite (authentification, contrôles d’accès, manipulation de requêtes).
3. Campagnes d’injection (sqlmap + tests manuels).
4. Vérification de la configuration sensible (secrets, debug, CORS, uploads).

7.2 Architecture de protection retenue

TABLE 7.1 – Mécanismes de protection par couche

Couche	Contrôles appliqués
Backend PHP	JWT, RBAC, tenant scoping par <code>store_id</code> , middleware CSRF, rate limiting.
ML Service FastAPI	Vérification <code>X-API-Key</code> /Bearer via <code>verify_api_key</code> sur tous les routers.
Frontend	<code>AuthGuard</code> sur routes protégées, gestion des erreurs de rendu.
Données et configuration	Requêtes paramétrées, suppression de secrets versionnés, templates <code>.env.example</code> .

7.3 Synthèse des corrections intégrées

TABLE 7.2 – Synthèse des vulnérabilités corrigées (V-01 à V-10)

Famille de risque	Correction appliquée dans le projet
Exposition de secrets	Nettoyage des clés sensibles dans les fichiers suivis, configuration par variables d’environnement.
Accès non autorisé / IDOR	Contrôles d’accès renforcés (RBAC + scoping tenant) et garde frontend.
Injection SQL	Paramétrisation systématique des requêtes, y compris pagination.
Attaques d’état (CSRF)	Middleware CSRF + en-tête applicatif côté client.
Abus d’API / flooding	Rate limiting sur groupes de routes sensibles.
Upload malveillant	Validation type/taille/nom et blocage de path traversal.

7.4 Préconisations de déploiement

- imposer HTTPS sur toutes les couches exposées,
- activer la rotation périodique des secrets (JWT, ML API key, LLM key),
- journaliser les rejets de sécurité (auth, CSRF, rate-limit),
- planifier un pentest externe avant déploiement à grande échelle.

7.5 Revue finale de cohérence

Une vérification croisée a été menée entre schémas, routes et implémentation effective. Les points suivants sont alignés :

- architecture Frontend-Backend-ML conforme aux schémas `architecture_globale` et `ai_integration`,
- modèle de données conforme aux migrations (12 tables métier et isolation multi-tenant),
- cycle de vie des commandes cohérent avec le `ENUM status`,
- endpoints de réentraînement et d’insights conformes au code actuel.

Les ajustements documentaires finaux ont aussi été validés, notamment la correction de la page de garde et l’harmonisation du vocabulaire utilisé dans la partie sécurité.

Conclusion Générale

Ce projet a abouti à un CRM intelligent exploitable pour le contexte COD algérien, avec une chaîne complète de la donnée brute jusqu'à la décision opérationnelle.

Synthèse des apports :

- architecture multi-tenant cohérente (frontend, backend, microservice ML),
- démarche méthodologique réaliste (benchmark Olist puis adaptation CRM),
- trois modules IA intégrés (risque, segmentation, prévision) avec indicateurs mesurables,
- sécurisation applicative renforcée (authentification, contrôles d'accès, protections anti-abus).

Perspectives :

- multiplier les réentraînements sur données réelles pour stabiliser les performances en production,
- enrichir les covariables métier (saisonnalité commerciale, campagnes marketing, effets logistiques),
- industrialiser l'exploitation (CI/CD, supervision avancée, tests de sécurité externes).

Bibliographie

- [1] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE : Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [2] H. He, Y. Bai, E. A. Garcia, and S. Li, “ADASYN : Adaptive Synthetic Sampling Approach for Imbalanced Learning,” in *Proceedings of the IEEE International Joint Conference on Neural Networks*, pp. 1322–1328, 2008.
- [3] T. Chen and C. Guestrin, “XGBoost : A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, 2016.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM : A Highly Efficient Gradient Boosting Decision Tree,” in *Advances in Neural Information Processing Systems 30*, pp. 3146–3154, 2017.
- [5] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, “CatBoost : Unbiased Boosting with Categorical Features,” in *Advances in Neural Information Processing Systems 31*, pp. 6638–6648, 2018.
- [6] S. J. Taylor and B. Letham, “Forecasting at Scale,” *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018.
- [7] L. McInnes, J. Healy, and S. Astels, “hdbscan : Hierarchical density based clustering,” *Journal of Open Source Software*, vol. 2, no. 11, p. 205, 2017.
- [8] L. Grinsztajn, E. Oyallon, and G. Varoquaux, “Why do tree-based models still outperform deep learning on tabular data?” in *Advances in Neural Information Processing Systems 35*, 2022.
- [9] Olist, “Brazilian E-Commerce Public Dataset by Olist,” Kaggle, 2018. [Online]. Available : <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- [10] A. F. Ansari, L. Stella, C. Turkmen, X. Zhang, P. Mercado, H. Shen, O. Shchur, S. S. Rangapuram, S. P. Arango, S. Kapoor, J. Zschiegner, D. C. Maddix, M. W. Mahoney, K. Torkkola, A. G. Wilson, M. Bohlke-Schneider, and Y. Wang, “Chro-

nos : Learning the Language of Time Series,” *arXiv preprint arXiv :2403.07815*, 2024.